

Advanced Machine Learning

Assignment 1

Villa Emma - 885906

1 Introduzione

Lo scopo di questo progetto è quello di progettare, implementare e addestrare una rete neurale fully-connected per risolvere un problema di classificazione. Il dataset che è stato scelto è l'Adult Income Dataset prelevato da Kaggle. L'obiettivo è quello di predire se il reddito di una persona è maggiore o inferiore ai 50.000 dollari, basandosi su informazioni demografiche e lavorative.

2 Dataset e analisi esplorativa

Il dataset Adult Income è composto da 48.842 campioni e 15 attributi, di cui 8 categorici e 6 numerici, che descrivono caratteristiche demografiche, professionali e sociali di individui adulti statunitensi.

Variabili categoriche:

- workclass: la categoria professionale.
- education: il titolo di studio in possesso.
- marital-status: stato civile dell'individuo.
- occupation: la professione.
- relationship: la posizione all'interno della gerarchia familiare.
- race: l'etnia dell'individuo.
- gender: il sesso biologico.
- native-country: il paese di origine.

Variabili numeriche:

- age: l'età dell'individuo.
- fnlwgt: peso campionario, che indica quante persone il campione rappresenta.
- education-num: valore numerico corrispondente al livello di istruzione.
- capital-gain: guadagni di capitale.
- capital-loss: perdite di capitale.
- hours-per-week: media delle ore lavorate in una settimana.

Income è la variabile target che indica la fascia di reddito annuale, che assume due possibili valori $\leq 50k$ oppure $> 50k$.

Un'analisi preliminare dei dati, ha mostrato la presenza di valori mancanti, marcati con '?', nelle colonne workclass (5,73%), occupation (5,75%) e native-country(1,75%).

Con l'obiettivo di analizzare la struttura del dataset è stata condotta un'analisi esplorativa tramite delle visualizzazioni grafiche:

- Per le variabili numeriche sono stati realizzati grafici di tipo histplot, utili per visualizzare la distribuzione e le eventuali asimmetrie. Per esempio, variabili come capital-gain e capital-loss hanno una predominanza marcata del valore 0. Inoltre, è stata realizzata una matrice di correlazione, che ha mostrato una correlazione tra le variabili molto bassa.
- Per le variabili categoriche sono stati prodotti grafici di tipo countplot, che mostrano la frequenza di ciascuna categoria. Viene mostrato che quasi la totalità degli individui ha come native-country gli Stati Uniti, per race il valore predominante è White e workclass è in predominanza Private.
- Per la variabile target, income, è stato fatto un countplot, che ha evidenziato una forte asimmetria nella distribuzione della variabile target, con circa il 75% degli individui appartenenti alla classe $\leq 50k$ e solo il 25% appartenenti alla classe $> 50k$.

3 Preprocessing

Il processo di preprocessing ha l'obiettivo di pulire e uniformare il dataset per renderlo compatibile con l'addestramento. Si vuole ottenere un dataset completamente numerico, con le variabili numeriche normalizzate.

3.1 Gestione dei valori mancanti

Nel dataset originale, alcune variabili categoriche contenevano valori mancanti. Questi casi rappresentavano circa il 7,41% del dataset, pari a 3.620 record su 48.842 osservazioni complessive. La scelta che è stata presa è quella dell'eliminazione dei record che contenevano un valore mancante, dovuta alla bassa percentuale di dati mancanti, che non comprometteva la rappresentatività del campione.

Un'alternativa valida sarebbe potuta essere quella di creare una categoria aggiuntiva Unknown per rappresentare i valori mancanti.

3.2 Rimozione di colonne

Gli attributi education (es: HS-grad) e educational-num (es: 9) rappresentano la stessa informazione. Infatti esiste un mapping univoco tra le due, che è stato evidenziato durante l'analisi esplorativa dei dati. Si è scelto di eliminare education e di mantenere educational-num, che ha già una rappresentazione ordinale corretta. È stata rimossa anche la variabile fnlwgt, in quanto rappresentava un peso statistico e non una caratteristica intrinseca dell'individuo.

3.3 Codifica delle variabili categoriche:

La variabile target income è stata trasformata in valori numerici, 0 e 1, tramite LabelEncoder. Dove 1 rappresenta $> 50k$, mentre 0 rappresenta $\leq 50K$.

Le variabili categoriche sono state trasformate in un formato numerico tramite One-Hot encoding. Tale metodo crea una variabile binaria per ciascuna categoria, permettendo alla rete neurale di interpretare le informazioni in maniera non ordinale. Infatti One-Hot encoding evita di introdurre una relazione ordinale fittizia tra categorie non ordinate.

3.4 Normalizzazione delle variabili numeriche:

Le feature numeriche sono state normalizzate con l'utilizzo di StandardScaler, che trasforma i dati in una distribuzione che ha media 0 e deviazione standard uguale a 1. Questo passaggio è fondamentale a causa della forte disparità di scala osservata nella fase esplorativa, infatti le reti neurali sono sensibili a variabili con scale molto diverse.

es: age ha una scala che va da 17 a 90 mentre capital gain ha una scala che va da 0 a 100k.

3.5 Suddivisione del dataset

Il dataset, una volta pulito, è stato suddiviso in due parti: training set (80%) utilizzato per l'addestramento del modello e validation set (20%) destinato alla valutazione finale delle prestazioni. La suddivisione è stata effettuata con `train_test_split()` utilizzando: `random_state = 42`, per garantire la riproducibilità dei risultati e `stratify = y`, per mantenere le proporzioni tra le classi $\leq 50k$ e $> 50k$ sia nel training set che nel test set. Operazione necessaria visto che la variabile income è fortemente sbilanciata.

4 Modello di base

Una volta completata la fase di preprocessing, i dati puliti e suddivisi sono stati utilizzati per l'addestramento di una rete neurale fully-connected. È stato implementato un modello Sequential di Keras, con lo scopo di stabilire una performance di partenza e identificare le problematiche dell'architettura e degli iperparametri scelti.

4.1 Architettura e funzioni di attivazione

La rete neurale è composta da un Input layer, tre layer nascosti, rispettivamente di 128, 64 e 32 neuroni e un layer di output. Si è scelta un'architettura con un numero decrescente di neuroni nei layer nascosti, con l'obiettivo di consentire al primo strato di catturare le interazioni tra le 87 feature in ingresso e successivamente comprimere e filtrare le informazioni nei layer successivi.

Per i layer nascosti è stata utilizzata la funzione di attivazione ReLU, che è una funzione standard in quanto è molto efficiente e aiuta a mitigare il problema del vanish gradient. Per il layer di output, è stata scelta la funzione Sigmoid che restituisce un valore tra 0 e 1. L'output viene interpretato come la probabilità che il campione appartenga alla classe 1 ($> 50k$).

4.2 Scelta degli iperparametri

Per la funzione di loss è stata utilizzata la `binary_crossentropy`, che è la scelta standard per i problemi di classificazione binaria perchè misura la distanza tra le probabilità predette e i valori reali. Come ottimizzazione è stato scelto di utilizzare Adam, che come default ha un learning rate di 0.001 e come metrica per monitorare il modello è stata scelta l'accuracy.

4.3 Analisi dei risultati

Il modello è stato addestrato per 50 epoche ed è stato utilizzato un validation split del 10% per monitorare l'andamento del modello anche su dati mai visti. Il modello di base ha ottenuto un'accuracy del 83% e una loss del 55%.

La training loss ha continuato a diminuire costantemente per quasi tutte le 50 epoche, mentre la validation loss ha smesso di diminuire praticamente subito ed ha iniziato a salire. Le curve di accuratezza mostrano lo stesso fenomeno, la training accuracy ha continuato a salire mentre la validation accuracy ha un comportamento oscillante. Il divario che si è creato tra la curva di training accuracy e quella di validation indica che il modello sta imparando a memoria i dati di training e sta perdendo la capacità di generalizzare sui nuovi dati.

È stata effettuata un'analisi più approfondita delle performance tramite la matrice di confusione e il report di classificazione in forma tabellare. Si può notare, tramite entrambi questi elementi, che il modello classifica molto bene la classe maggioritaria ($\leq 50K$), con una precision del 0,87 e recall del 0,91, mentre fa più fatica con la classe minoritaria ($> 50k$) in cui la precision risulta di 0,68 e la recall di 0,59. Inoltre anche la matrice di confusione mostra che si classificano nel modo corretto 6181 record appartenenti alla classe maggioritaria e solo 1332 record appartenenti alla classe minoritaria. Questo risultato è coerente con lo sbilanciamento del dataset che penalizza la capacità del modello di riconoscere redditi più alti.

Infine, è stata calcolata e rappresentata la curva ROC e la relativa area AUC che risulta 0,87.

4.4 Analisi degli errori

L'analisi degli errori sottolinea, come aveva già fatto in precedenza la matrice di confusione, che il modello produce più falsi negativi (910) piuttosto che falsi positivi (622). Dove i falsi positivi sono gli individui con reddito $\leq 50K$ che sono stati classificati come $> 50k$.


Tra i falsi positivi si notano individui con un buon livello di istruzione, sposati o con posizioni professionali elevate. Tra i falsi negativi, invece, si notano individui con un'istruzione bassa oppure che non sono sposati.

5 Modello migliorato

L'analisi dei risultati del modello base ha mostrato buone prestazioni complessive ma ha mostrato anche delle problematiche, come il divario tra training e validation loss che rappresenta overfitting oppure la ridotta capacità di riconoscere la classe minoritaria. Sulla base di queste osservazioni e di alcune prove empiriche effettuate, sono state scelte le modifiche da effettuare nel nuovo modello.

5.1 Architettura e iperparametri

La funzione di attivazione per i layer nascosti e dell'output layer erano già la scelta ottimale per il modello, quindi non sono state modificate.



Riduzione complessità della rete: L'analisi dei grafici ha suggerito che la capacità di rappresentazione della rete era eccessiva rispetto alla complessità del problema. Infatti, la nuova architettura è formata da due soli layer nascosti con 32 e 16 neuroni.

Introduzione del Dropout: Per limitare ulteriormente l'overfitting è stato inserito il Dropout dopo i layer nascosti, rispettivamente del 30% e del 20%, in modo da disattivare casualmente alcuni neuroni durante l'addestramento per forzare la rete a generalizzare di più.

Riduzione del learning rate: Analizzando la curva di training loss si è notato che inizialmente scendeva molto rapidamente quindi è stato impostato un learning rate di 0.007, leggermente inferiore allo standard per avere una convergenza più graduale e diminuire le oscillazioni.

Introduzione early stopping: È stata utilizzata la tecnica di Early Stopping, con monitoraggio della validation loss e una pazienza di 5 epoche. Se la validation loss non migliora per 5 iterazioni l'addestramento viene interrotto, con l'obiettivo di non addestrare il modello per troppe epoche. L'opzione `restore_best_weights=True` permette di ripristinare, al termine del training, i valori migliori osservati. L'addestramento del modello si ferma a 23 epoche, questo valore rappresenta il punto in cui il modello smette di imparare dai dati di addestramento e inizia ad adattarsi ai dati di training.




5.2 Analisi dei risultati

Il modello migliorato ha ottenuto un'accuracy del 85% e una loss del 31%. Rispetto al modello base c'è un miglioramento significativo della loss (-0.23%) e un leggero incremento dell'accuratezza (+ 0.02%).

La training loss diminuisce rapidamente nelle prime epoche, mentre la validation loss decresce in modo regolare fino a stabilizzarsi intorno alla ventesima epoca. Il grafico in cui viene rappresentata l'accuracy mostra una crescita rapida nelle prime epoche, seguita da una fase di stabilizzazione tra le 15 e le 20 epoche. La curva di validation accuracy ha lo stesso comportamento di quella di training, le due curve restano vicine per tutto il training, questo mostra che il modello ha imparato in modo stabile senza avere un overfitting marcato.

È stata effettuata anche in questo caso un'analisi più approfondita delle performance tramite la matrice di confusione e il report di classificazione in forma tabellare. Dal classification report si osserva che per la classe classe maggioritaria ($\leq 50K$) il modello raggiunge una precision di 0,88 e recall di 0,93 mentre per la classe minoritaria ($> 50k$) si ottiene una precision di 0,73 e una recall di 0,62. La classe minoritaria rimane più difficile da classificare, ma il nuovo modello riesce a classificarla meglio rispetto al modello precedente. Il valore dell'AUC è pari a 0,90, e indica che il modello ha una buona capacità discriminativa. Un'analisi qualitativa degli errori mostra la presenza di 481 falsi positivi e 903 falsi negativi, meno rispetto al modello precedente.

Le curve di apprendimento regolari, la riduzione della loss e la stabilità della validation accuracy indicano che l'introduzione di Dropout ed Early Stopping, abbinata al miglioramento dell'architettura della rete e degli iperparametri ha effettivamente migliorato la capacità di generalizzazione del modello, prevenendo l'overfitting che invece era presente nel primo modello.



6 Possibili miglioramenti

Nonostante i miglioramenti ottenuti con il secondo modello, rimane il problema del riconoscimento della classe minoritaria ($> 50k$). Si potrebbe assegnare un peso maggiore alla classe minoritaria in modo che la funzione di loss penalizzi maggiormente gli errori su questa classe. Si potrebbe inoltre, come già accennato, gestire i valori mancanti con la creazione di una nuova categoria "unknown" e utilizzare una tecnica sistematica come GridSearch per ottimizzare gli iperparametri.